

1. ความเป็นมาและความสำคัญของปัญหา

การใช้พลังงานไฟฟ้าในประเทศไทยมีอัตราเพิ่มขึ้นอย่างต่อเนื่อง โดยการใช้พลังงานไฟฟ้าส่วนใหญ่นั้นเกิดขึ้นในส่วนครัวเรือน ดังนั้นถ้าสามารถลดปริมาณไฟฟ้าในส่วนนี้ลงไปได้จะเกิดประโยชน์อย่างมากโดยหนึ่งในวิธีการที่ง่ายคือการสำรวจพฤติกรรมการใช้งานเครื่องใช้ไฟฟ้าและปรับใช้ตามความเหมาะสมเพื่อให้เกิดประโยชน์สูงสุดแต่เนื่องจากการตรวจสอบพฤติกรรมการใช้เครื่องใช้ไฟฟ้า ต้องตรวจวัดการใช้ไฟฟ้าเครื่องใช้ไฟฟ้าแต่ละอุปกรณ์ซึ่งอาจจะไม่คุ้มค่าต่อการลงทุน จึงเป็นที่มาของปัญหาว่าจะสามารถใช้อุปกรณ์ตรวจวัดการใช้ไฟฟ้าเครื่องใช้ไฟฟ้าเพียงจุดเดียวและสามารถบอกได้ว่า ณ เวลานั้น ๆ อุปกรณ์อะไรบ้างทำงานอยู่และใช้พลังงานเท่าไร

การประมาณการใช้พลังงานของเครื่องใช้ไฟฟ้าด้วยการตรวจสอบการใช้พลังงานของเครื่องใช้ไฟฟ้าแบบไม่รบกวน หรือ NILM เป็นเทคนิคการประมาณการใช้พลังงานไฟฟ้าของเครื่องใช้ไฟฟ้าแต่ละเครื่องจากมิเตอร์เพียงเดียว ซึ่งวัดค่าการใช้พลังงานไฟฟ้าของเครื่องใช้ไฟฟ้าหลายชนิดรวมกันสามารถนำมาประยุกต์ใช้กับการตรวจสอบพฤติกรรมผู้ใช้อุปกรณ์เครื่องใช้ไฟฟ้า การปรับปรุงการใช้เครื่องใช้ไฟฟ้าของผู้ใช้ ตรวจสอบความผิดพลาดหรือความผิดปกติของเครื่องใช้ไฟฟ้า รวมถึงการช่วยให้ผู้ใช้ลดการใช้งานพลังงานไฟฟ้า งานวิจัยช่วงแรกของ NILM จะใช้การสร้างคุณลักษณะของอุปกรณ์ไฟฟ้าโดยใช้ความรู้ของผู้เชี่ยวชาญเป็นหลัก เช่น การแปลงคุณลักษณะที่ไม่แปรผันตามอัตราส่วน (Scale-invariant feature transform (SIFT)) และ ความแตกต่างของเกาส์เซียน (Difference of Gaussians: DoG)) [1] ถัดมามีเทคโนโลยีที่ช่วยในการสกัดคุณลักษณะเฉพาะโดยอัตโนมัติสำหรับการแก้ปัญหาการจำแนกประเภทข้อมูลภาพที่แก้ปัญหา ImageNet และสามารถเพิ่มประสิทธิภาพการจำแนกได้ โดยการใช้แบบจำลองโครงข่ายประสาทแบบลึกจำแนกประเภทข้อมูลแบบอัตโนมัติแทนการจำแนกประเภทข้อมูลด้วยมือ ทำให้แบบจำลองโครงข่ายประสาทแบบลึกเป็นอัลกอริทึมที่สามารถสร้างคุณลักษณะเฉพาะแบบอัตโนมัติที่ประสิทธิภาพสูง รวมถึงสามารถนำไปประยุกต์ใช้แก้ปัญหาในสาขาอื่น ๆ ได้ เช่น การรู้จำเสียงอัตโนมัติ, การแปลด้วยเครื่อง เป็นต้น อย่างไรก็ตามแบบจำลองโครงข่ายประสาทนั้นไม่สามารถเรียนรู้และจำแนกคุณลักษณะเฉพาะได้อย่างมีประสิทธิภาพ [2] เนื่องจากข้อจำกัดสองประการคือความสามารถในการประมวลผลและจำนวนข้อมูล ในปัจจุบันเนื่องจากตัวประมวลผลที่มีประสิทธิภาพสูงขึ้นรวมถึงข้อมูลที่มีจำนวนมากขึ้น ทำให้สามารถฝึกแบบจำลองโครงข่ายประสาทแบบลึกและสามารถสกัดคุณลักษณะแบบอัตโนมัติออกมาได้ และมีการประยุกต์ใช้แก้ปัญหาการประมาณการใช้พลังงานของเครื่องใช้ไฟฟ้า [3]

ปัจจุบันมีการประยุกต์ใช้โครงข่ายประสาทแบบลึกสำหรับแก้ปัญหาการใช้พลังงานของเครื่องใช้ไฟฟ้า พบว่าโครงข่ายประสาทแบบลึกแบบมีประสิทธิภาพสูงกว่าแบบจำลองการหาค่าเหมาะสม

ที่สุดเชิงการจัด (Combinatorial optimisation) และแบบจำลองมาร์คอฟซ่อนเร้น (Factorial hidden Markov models) ทั้งในข้อมูลเรียนรู้และข้อมูลทดสอบ จึงเป็นที่มาของวิทยานิพนธ์นี้ที่จะประยุกต์ใช้แบบจำลองโครงข่ายประสาทแบบลึกในการจำแนกประเภทข้อมูลภาพและเทคโนโลยีรู้จำเสียงพูดแบบต่อเนื่องเข้าด้วยกัน คือ แบบจำลองโครงข่ายประสาทการเข้ารหัสคอนโวลูชันอัตโนมัติและแบบจำลองโครงข่ายประสาทคอนโวลูชันแบบลึก และเปรียบเทียบประสิทธิภาพกับอัลกอริทึมมาตรฐานสองแบบ คือ แบบจำลองการหาค่าเหมาะสมที่สุดเชิงการจัดและแบบจำลองมาร์คอฟซ่อนเร้น ในการประมาณการใช้พลังงานของเครื่องใช้ไฟฟ้า

2. วัตถุประสงค์

1. เพื่อประยุกต์ใช้แบบจำลองโครงข่ายประสาท ในข้อมูลการตรวจสอบการใช้พลังงานของเครื่องใช้ไฟฟ้าแบบไม่รบกวน (NILM)
2. เพื่อตรวจสอบความผิดพลาดหรือความผิดปกติของเครื่องใช้ไฟฟ้า
3. เพื่อตรวจสอบพฤติกรรมผู้ใช้ไฟฟ้าต่อการใช้เครื่องใช้ไฟฟ้า

3. ขอบเขตของการวิจัย


เปรียบเทียบประสิทธิภาพในการตรวจสอบการใช้พลังงานของเครื่องใช้ไฟฟ้าแบบไม่รบกวนแบบจำลองการหาค่าเหมาะสมที่สุดเชิงการจัด แบบจำลองมาร์คอฟซ่อนเร้น แบบจำลองโครงข่ายประสาทการเข้ารหัสคอนโวลูชันอัตโนมัติและแบบจำลองโครงข่ายประสาทคอนโวลูชันแบบลึก โดยทำการทดสอบกับชุดข้อมูลสาธารณะ UK-Dale โดยเป็นข้อมูลการใช้ไฟฟ้าของกาต้มน้ำ, เครื่องล้างจาน, ตู้เย็น, ไมโครเวฟ, เครื่องซักผ้า จากบ้านทั้ง 5 หลังช่วงระยะเวลาปี ค.ศ. 2011 ถึง 2015 โดยเป็นข้อมูลสุ่มตัวอย่างทุก ๆ 1 วินาที

4. วิธีการทดลอง

4.1 ทฤษฎีที่ประยุกต์ใช้


Neural Network มีลักษณะการทำงานแบบ การทำกราฟมีทิศทางโดยกำหนดแต่ละจุดยอดเป็นเซลล์ประสาทเทียมและเส้นเชื่อมเป็นการส่งข้อมูลไปยังเซลล์ประสาทเทียมในชั้นอื่น ๆ โดยปกติเซลล์ประสาทจะถูกจัดเรียงเป็นชั้น ๆ เซลล์ประสาทแต่ละเซลล์ในชั้น l จะเชื่อมต่อกับเซลล์ประสาททุกเซลล์ในชั้นถัดไป $l + 1$ และแต่ละการเชื่อมต่อคือตัวถ่วงน้ำหนัก แบบจำลองโครงข่ายประสาทมีชั้นที่เป็นชั้นรับข้อมูลเข้าและ ชั้นส่งข้อมูลออก ชั้นที่อยู่ระหว่างทั้งสองชั้นนั้นจะถูกเรียกว่า ชั้นซ่อน การเรียนรู้เกิดจากการปรับเปลี่ยนน้ำหนักของตัวถ่วงน้ำหนักเหล่านี้โดยจะเกิดขึ้นระหว่างการส่งย้อนกลับเซลล์ประสาท

เทียมแต่ละตัวจะคำนวณและผลรวมผลค่าอินพุตกับค่าถ่วงน้ำหนักและค่าอคติ (bias) และ ผ่าน ฟังก์ชันกระตุ้น



รูปที่ 1 แบบจำลองเซลล์ประสาท

จากรูปที่ 1 เซลล์ประสาทที่รับอินพุต I เข้ามา ค่าของแต่ละอินพุตแสดงด้วยเวกเตอร์ x ค่าถ่วงน้ำหนักการเชื่อมต่อ i ไปยังเซลล์ประสาท n แสดงด้วย w_{in} แสดงด้วยเวกเตอร์ w ผลรวมค่าถ่วงน้ำหนักของเซลล์ n สามารถเขียนได้ $\sum_{i=0}^{I-1} (x_i w_{in})$ หรือ a_n ผ่าน ฟังก์ชันกระตุ้น θ เพื่อให้ได้ค่าตอบสุดท้ายของเซลล์ประสาท n เรียกว่า b_n




รูปที่ 2 แสดงค่าที่เปลี่ยนไปในแต่ละฟังก์ชันกระตุ้น

จากรูปที่ 2 ฟังก์ชันกระตุ้นที่ถูกใช้ เชิงเส้น $linear\theta(x) = x$, $ReLU\theta(x) = \max(x, 0)$, $likelyReLU\theta(x) = \max(x, 0.01x)$ การใช้ฟังก์ชันกระตุ้นที่ไม่เป็นเชิงเส้นหลาย ๆ ชั้นต่อกันมีส่วนช่วยให้แบบจำลองโครงข่ายประสาททำงานได้ดียิ่งขึ้น


แนวคิดพื้นฐานของการส่งกลับให้ส่งไปด้านหน้าก่อนจากนั้น ทำการคำนวณค่าคลาดเคลื่อนเทียบเป้าหมาย(ค่าเฉลี่ยผลต่างกำลังสอง mean squared error (MSE)) จากนั้นปรับเปลี่ยนตัวถ่วงน้ำหนักตามทิศทางที่ควรเป็นเพื่อลดค่าคลาดเคลื่อน การปรับเปลี่ยนค่าตัวถ่วงน้ำหนักโดยใช้ อัลกอริทึมลดตามความชันคำนวณค่าความชันค่าคลาดเคลื่อนของแต่ละเซลล์ในแต่ละชั้นจากนั้นปรับค่าตัวถ่วงน้ำหนักไปตามความชันและ พารามิเตอร์ อัตราการเรียนรู้

แนวคิดการพิจารณาข้อมูลเข้าเฉพาะส่วนเล็ก ๆ การสนใจคุณลักษณะเฉพาะส่วนเล็ก ๆ รวมถึงการทับซ้อนกันของส่วนข้อมูลย่อยในข้อมูลเข้า แทนที่การพิจารณาข้อมูลทั้งหมด การประยุกต์มาใช้งานอนุกรมเวลาจะเป็นการสนใจเฉพาะส่วนเวลาเล็ก ๆ ของอินพุต แทนที่จะสนใจทั้งช่วงเวลา



รูปที่ 3 ตัวอย่างแบบจำลองโครงข่ายประสาทคอนโวลูชันแบบลึก

แนวคิดการแบ่งส่วนเวลาออกเป็นหลายๆ ส่วนโดยแต่ละส่วนจะมีส่วนทับซ้อนกับส่วนถัดไป จากนั้นทำการหาความถี่ของข้อมูลช่วงนั้น ๆ ที่เปลี่ยนแปลงไปตามเวลา โดยที่ผลลัพธ์ที่ได้จากการแปลงฟูเรียร์ช่วงเวลาสั้นจะเปลี่ยนข้อมูลจากข้อมูลจากหนึ่งมิติ ไปเป็นข้อมูลสองมิติ



รูปที่ 4 ตัวอย่างการแปลงฟูเรียร์ช่วงเวลาสั้น (ซ้าย) ตัวอย่างสัญญาณสองช่วงความถี่ (ขวา)

4.2 ข้อมูล

เนื่องจากข้อมูลมีอัตราส่วนตัวอย่างต่อเวลาไม่เท่ากัน (1 วินาที ถึง 6 วินาที) แต่แบบจำลองต้องการข้อมูลที่มีช่วงเวลาที่เท่ากันและสม่ำเสมอ ทำให้จำเป็นต้องเปลี่ยนอัตราส่วนตัวอย่างต่อเวลาเป็นทุก ๆ 10 วินาที โดยให้ค่าการใช้พลังงานที่ได้เป็นค่าเฉลี่ยของข้อมูลตัวอย่าง พลังงานทั้งหมดในช่วงเวลา

นั้น ๆ จากนั้นเปลี่ยนช่วงเวลาที่ไม่พบข้อมูลให้เป็นศูนย์ เมื่อข้อมูลครบทุกช่วงและมีอัตราตัวอย่างที่คงที่ แล้วทำการตัดแบ่งข้อมูลทุก ๆ 8,640 (8,640 ตัวอย่างคูณ 10 วินาทีเท่ากับ 86,400 วินาที หรือเท่ากับ 1 วัน) ตัวอย่างออกจากกันเพื่อให้ช่วงข้อมูลเข้าแบบจำลองมีความคงที่

แบ่งข้อมูลเป็นสองชุด โดยข้อมูลชุดแรกเป็นข้อมูลสำหรับฝึกสอน (ระยะเวลา 2 ปี หรือ 730 วัน) และ ข้อมูลชุดที่สองสำหรับทดสอบแบบจำลอง (ระยะเวลา 3 เดือน หรือ 90 วัน) ในกรณีแบบจำลองคอนโวลูชันหนึ่งมิติ สามารถใช้ข้อมูลได้เลย แต่ถ้าเป็นแบบจำลองคอนโวลูชันสองมิติจำเป็นจะต้องแปลงฟูเรียร์ช่วงเวลาสั้น

4.3 การวิเคราะห์ข้อมูล

นำข้อมูลไปป้อนให้แบบจำลองเรียนรู้

การเข้ารหัสอัตโนมัติ autoencoder (AEs) เป็นเครือข่ายที่พยายามสร้างอินพุตใหม่ โดยการเข้ารหัสอัตโนมัติจะพยายามสร้างอินพุตใหม่ (พื้นที่ซ่อนเร้นหรือ ชั้นรหัส) จากอินพุตที่ป้อนเข้าไปจากนั้นถอดรหัสอินพุตนั้น การสร้างพื้นที่ซ่อนเร้นนั้นสามารถทำได้จากการทำให้เกิดคอขวดในชั้นใดชั้นหนึ่งของเลเยอร์ในแบบจำลองโครงข่ายประสาท จึงทำให้พื้นที่ซ่อนเร้นมีขนาดเล็กกว่าขนาดของอินพุตเดิม

การเข้ารหัสอัตโนมัติ นั้นอาจจะเทียบได้กับการทำ การวิเคราะห์องค์ประกอบหลัก (PCA) แต่การเข้ารหัสอัตโนมัตินั้นสามารถทำแบบไม่เชิงเส้นได้กำหนดให้ส่วนเข้ารหัสเป็น คอนโวลูชันนอลที่มีขนาดฟิลเตอร์ลดลงและ จำนวนฟิลเตอร์เพิ่มขึ้น จนถึงชั้นพื้นที่ซ่อนเร้น ถัดมาส่วนถอดรหัสใช้ ดีคอนโวลูชันนอลที่มีขนาดฟิลเตอร์เพิ่มขึ้นและ จำนวนฟิลเตอร์ลดลง

5. ประโยชน์ของการวิจัย

แบบจำลองโครงข่ายประสาทที่เหมาะสมสำหรับปัญหา NILM
เข้าใจในพฤติกรรมการใช้เครื่องใช้ไฟฟ้าที่และพลังงานรวม
ทราบแนวทางการปรับลดการใช้พลังงานไฟฟ้าของเครื่องใช้ไฟฟ้า

6. รายชื่อเอกสารอ้างอิง

1. G. W. Hart. Nonintrusive appliance load monitoring. Proceedings of the IEEE, 80(12):1870–1891, Dec. 1992. doi:10.1109/5.192069.
2. G. W. Hart. Prototype nonintrusive appliance load monitor. Technical report, MIT Energy Laboratory and Electric Power Research Institute, Sept. 1985.

3. N. Amirach, B. Xerri, B. Borloz, and C. Jauffret. A new approach for event detection and feature extraction for nilm. In Electronics, Circuits and Systems (ICECS), 2014 21st IEEE International Conference on, pages 287–290. IEEE, 2014.